

24GB GPU 메모리 제약에서의 Budget-Conditioned Foveated Adapter Residency 비용 시뮬레이션 연구

후속 연구 논의를 위한 1차 소논문 초안

초록

피지컬 AI 시스템에서는 perception, planning, verification, world model 계층이 제한된 GPU 메모리를 함께 사용해야 한다. 본 초안은 실제 VLM 학습이나 HydraLoRA 계열 fine-tuning을 수행하기 전에, budget-conditioned foveated adapter residency 정책이 후속 연구 가치가 있는지 비용 시뮬레이션으로 확인한다. 총 4,032개 조건에서 대표 조건의 foveated input은 visual token을 75.0% 줄였고, 최종 B7-lite 구조는 full-resolution 기준선 대비 estimated peak memory를 21.9% 줄였다. 또한 shared-bank와 budgeted variant는 independent bank 대비 resident adapter memory를 각각 67.36%, 89.24% 줄였다.

핵심어: foveated inference; adapter residency; LoRA; GPU memory; cost simulation; physical AI

1. 서론

배치 관점의 피지컬 AI 루프는 가장 큰 비전 모델 하나를 띄우는 문제가 아니다. 실제 시스템에서는 perception 모델이 planner, verifier, orchestration layer, world model이 사용할 메모리 여유를 남겨야 한다. 따라서 이 연구는 어디를 볼지, 어떤 lightweight adapter를 활성화할지, 그리고 언제 유지하거나 내릴지를 메모리 예산 아래에서 결정하는 정책 문제로 접근한다.

제안 방향은 foveated input selection, LoRA 계열 local skill adapter, HydraLoRA식 공유 구조를 결합한다. 본 초안의 질문은 작다. 비싼 모델 학습 전에, 이 구조가 시뮬레이션 상에서 측정 가능한 메모리 비용 이득을 만드는가를 본다.

기여

- visual-token cost, adapter resident memory, temporary load buffer, orchestration reserve를 분리한 작은 cost model을 정의했다.
- full-resolution inference와 foveated ROI inference, independent adapter bank와 shared adapter bank를 비교했다.
- budget-conditioned residency가 simulator 안에서 reserve failure를 줄일 수 있음을 stress grid로 확인했다.

2. 방법

시뮬레이터는 RTX 3090 24GB 위의 proxy 7B VLM memory profile을 사용한다. 대표 조건은 base model 12GB, orchestration reserve target 4GB, full-resolution 1344 x 1344, global view 336 x 336, ROI crop 336 x 336 세 개, 후보 adapter 16개, active top-k=2로 둔다.

비교군은 여섯 개다. B0는 저해상도 global view만 쓰고, B1은 full-resolution 입력을 쓰는 비용 기준선이다. B2는 adapter 없이 ROI crop을 추가한다. B4-lite는 independent adapter bank가 모두 상주한다고 가정한다. B5-lite는 shared common component와 skill별 branch를 가정한다. B7-lite는 top-k, ROI, adapter-hold 조정을 수행하는 budget-conditioned controller를 추가한다.

평가 grid는 model profile, reserve target, 해상도, ROI 수, adapter 수, active top-k 값을 포함한다. 본 실험은 cost simulation이므로 정확도 주장은 하지 않는다.

3. 결과

대표 조건에서 B1 full-resolution 입력은 9216 visual token과 17.30GB estimated peak memory를 사용했다. B2 foveated ROI 입력은 2304 token을 사용해 token 수를 75.0% 줄였다. B7-lite는 13.51GB estimated peak memory를 기록했으며, 이는 B1 대비 21.9% 감소다.

비교군	토큰	Peak GB	Adapter GB	Reserve	Latency
B0	576	12.07	0.00	pass	48.3
B1	9216	17.30	0.00	pass	143.4
B2	2304	13.11	0.00	pass	67.3
B4-lite	2304	16.02	2.81	pass	103.3
B5-lite	2304	14.12	0.92	pass	83.3
B7-lite	2304	13.51	0.30	pass	83.3

표 1. 대표 조건의 시뮬레이션 결과.




그림 1. 대표 조건에서 비교군별 estimated peak memory.

전체 grid에서 B4-lite는 reserve failure 396건을 보였지만, B7-lite는 reserve failure 0건을 유지했고 1296건 중 148건에서 top-k, ROI, adapter hold 조정을 수행했다.

4. 논의

결과는 두 개의 자원 제어 축을 분리해 볼 수 있음을 보여준다. foveated input selection은 visual token과 activation 계열 비용을 줄이고, shared 또는 budgeted adapter residency는 skill specialization에 묶인 resident memory를 줄인다. policy formulation은 adapter 폭이나 ROI 수를 조정해 reserve safety를 확보할 수 있다는 점에서 유용하다.

한계

이 시뮬레이터는 profiler가 아니다. 실제 kernel-level memory allocation, VLM attention behavior, adapter loading overhead, task accuracy를 측정하지 않는다. adapter cost도 1차 가정값이므로 target VLM과 LoRA rank가 정해지면 실제 측정값으로 교체해야 한다.

결론과 다음 단계

24GB GPU cost simulation은 budget-conditioned foveated adapter residency가 실제 모델 실험으로 검증할 가치가 있음을 보여준다. 다음 단계는 작은 VLM을 대상으로 full-resolution 입력과 foveated 입력의 실제 peak memory를 측정하고, simulated adapter table을 실제 LoRA loading/residency cost로 교체하는 것이다.

참고문헌

Hu, E. J. 외 (2021). LoRA: Low-Rank Adaptation of Large Language Models. arXiv:2106.09685.

Tian, C. 외 (2024). HydraLoRA: An Asymmetric LoRA Architecture for Efficient Fine-Tuning. arXiv:2404.19245.

Maes, L. 외 (2026). LeWorldModel: Stable End-to-End Joint-Embedding Predictive Architecture from Pixels. arXiv:2603.19312.

Davidson, T. R. 외 (2026). Reasoning-Driven Synthetic Data Generation and Evaluation. arXiv:2603.29791.